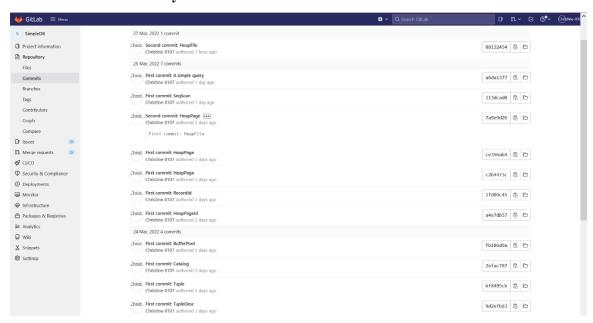
# SimpleDB Lab1 实验报告

## 2010239 李思凡

### 一、Lab1 概述

通过 Lab1,将实现对硬盘上存储数据的访问。在本次实验中,需要实现管理元组的类(TupleDesc, Tuple);实现目录类(Catalog);实现缓冲池(BufferPool);实现访问数据的类(HeapPageId, RecordId, HeapPage, HeapFile);以及实现一个操作类(SeqScan)。

## 二、Git Commit History



## 三、字段和元组(Fields and Tuples)

## (一) TupleDesc 类

#### 1.设计思路

TupleDesc 类主要描述这个表中的元组应该遵循的模式,即应该有的字段类型和名称。通过辅助类 TDItem 来定义,一个 TDItem 对象包括 fieldType 和 fieldName (字段类型和字段名) 两个属性。

- (1) 首先建立一个元素类型为 TDItem 的动态数组 tdItems, 向其中添加所有的 TDItem 对象; 对于 iterator()方法, 返回动态数组 tdItems 的 iterator()。
  - (2)在 TupleDesc 的构造函数里,只需将利用所给 type 和 name 创建 TDItem

对象, 并把所有该对象添加到 tdItems 中。

- (3) 通过调用动态数组的 size(), 可获得字段的数量。
- (4) 通过遍历 tdItems,可以获得每个索引对应元素的类型和名称;
- (5) 通过遍历 tdItems,可以将名称与给定的 name 做比较,若相等则返回对应的索引标号;
  - (6) 可以遍历得到每个类型的字节数,相加得到总的字节大小;
- (7) 也可以遍历并对每个对象调用 toString()方法,按照规定格式拼接成描述 TupleDesc 类的字符串。
  - (8) merge()方法和 equals()方法设计思路见重难点。

#### 2.重难点

(1) 合并两个 TupleDesc。(merge()方法)

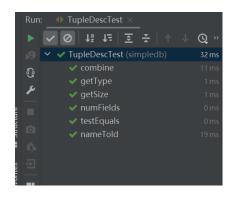
开辟长度为两个 TupleDesc 长度之和的数组 type 和 name, 先遍历第一个 TupleDesc, 获取它的类型和名称, 填入 type 和 name 的前面, 再遍历第二个 TupleDesc 的类型和名称,填入后面。再利用 type 和 name 数组创建新的 TupleDesc 对象并返回。

(2) 比较给出的对象与该 TupleDesc 是否相等。(equals()方法)

首先判断给出的对象 obj 是否为空、是否也为 TupleDesc 类型,若为空或不是同一类型则不相等。再比较 obj 中字段数量和该 TupleDesc 中字段数量是否相等,若数量不等也不相等。最后遍历所有字段,依次比较类型和名称是否相等,若全部相等则两个对象相等。

对其余类对象的比较同理。

- 3.改动部分:未改动 API 和测试代码。
- 4.test 测试结果如下:



#### (二) Tuple 类

#### 1.设计思路

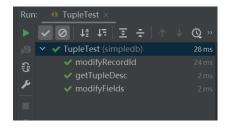
Tuple 类保存表中所有元组的信息,遵循 TupleDesc 定义的模式。

- (1) 首先需要在 Tuple 类中添加所需属性: TupleDesc 类的对象 tupleDesc 用来表示所需遵循的模式,元素类型为 Field 的动态数组 tupleField 存各种字段的数据,以及 RecordId 类的对象 recordId 用来标识各记录。
- (2) 在 Tuple 类的构造函数中,根据传进来的参数初始化 tupleDesc,表示要遵循的模式,并根据该 tupleDesc 中字段的数量初始化动态数组 tupleFields 的大小,并将其中元素先初始化为空值。
  - (3) 获取 TupleDesc 的 getTupleDesc()方法只需返回相应属性。
- (4) 获取 RecordId 的 getRecordId()方法只需返回相应属性。设置 RecordId 的 setRecordId()方法中,将类中属性 recordId 设置为传进的参数。
- (5) 通过 setField()方法改变元组中第 i 个字段,调用动态数组 tupleField 的 set(i,f)方法。获取第 i 个字段的值,调用 tupleField 的 get(i)方法并返回。
- (6)通过 iterator()方法迭代元组中的所有字段,只需返回 tupleField 的 iterator 方法。
- (7) 遍历 tupleField 的每个元素获取其 toString 字符串,按照规定格式拼接成 Tuple 类的描述性字符串。
- (8) 对于 resetTupleDesc()方法,需要根据传进的参数重新初始化 tupleDesc 作为新的模式,并重置 tupleField 中所有元素为空。

#### 2.重难点

Tuple 类的重点在于需要准确确定本类所需添加的属性,并通过构造函数进行初始化。确定后其他的函数就比较容易添加。

- 3.改动部分:未改动 API 和测试代码。
- 4.test 测试如下(之后的类完善了 RecordId, 因此能通过 modifyRecordId 方法)



## 四、目录(Catalog)

#### 1.设计思路

- (1) Catalog 类中记录数据库中所有表和它们的模式。通过观察类中已给出方法的参数列表,可知向 Catalog 类中添加表需要三个参数: DbFile 对象 file (每个 DbFile 代表一个表,其中会为每个表设定一个独特的 ID),表的名称 name,每个表主键字段的名称 pkeyField。通过观察 Catalog 类中已添加函数的信息可知需要通过表的 ID 值定位表信息。因此可为 Catalog 类添加辅助类 Table,每个Table 对象代表一张表,Table 类中包括三个私有属性: DbFile 对象 dbFile,表的名称 tableName,主键字段的名称 primaryKey。为 Table 类添加构造函数,获取三个私有属性的函数和 toString()函数。
- (2) 为方便后续函数由表的 ID 找表、由表的名称找表的 ID,建立两个 ConcurrentHashMap,分别是<Integer,Table>的 hashTable 和<String,Integer>的 nameToId。在 Catalog 的构造函数中初始化这两个 map。
- (3)在 addTable()方法中,通过传进的三个参数创建 Table 类对象 newTable; 通过调用 file 对象的 getId()方法获取 tableId。调用 put 方法,向 hashTable 中添加键值对<tableId, newTable>,向 nameToTd 中添加键值对<name, tableId>。
- (4) 在 getTableId()方法中,通过建立的 nameToId 可以方便的使用名称查找 ID,根据查找结果进行返回。若给出的 name 为空值,则抛出异常。
- (5) 通过给出的 tableId 和 hashTable,可以很方便的找到对应的 Table,在 利用 Table 类中的获取方法,很容易获取相应的数据库文件、表名称和主键名称。
- (6) 在 getTupleDesc()方法中,通过给出的 tableId,调用 getDatabaseFile()即可获取相应的数据库文件,再调用 DbFile 类中的 getTupleDesc()方法即可获得该表对应的元组模式。
- (7) 在 tableIdIterator()方法中,通过调用 nameToId.values()获得键,即所有 tableId,再返回它的 iterator()。
- (8) clear()方法需要将目录中所有表清空,只需调用 hashTable 和 nameToId 的 clear()方法。

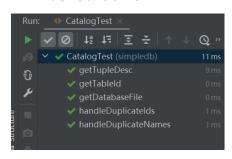
### 2.重难点

本类的重难点在于需要通过理解 Catalog 类的内容和观察已有方法,创建

Table 类,准确定义 Table 类中的三个属性;并建立两个 HashMap: <Integer,Table>的 hashTable 和<String,Integer>的 nameToId,方便后续的查找操作。

3.改动部分: 未改动 API 和测试代码。

4.test 测试结果如下:



## 五、缓冲池(BufferPool)

#### 1.设计思路

- (1) BufferPool 类负责将内存最近读过的物理页缓存下来,所有的读写操作通过 BufferPool 进行,将提高访问速度。BufferPool 中 pageSize 字段固定了每页的大小。通过观察 BufferPool 类中给出的构造函数参数,可知需增加一个属性 numPages 用来存缓冲池中最多容纳的页数。通过观察 getPage()方法可知,要通过缓冲池获取页,需要对应的 PageId,因此可以添加一个 HashMap,由 PageId 查找 Page,称为 buffer。
- (2) 在 BufferPool 的构造函数中,根据传进来的参数初始化 numPages,并初始化 buffer,长度设为 numPages。
  - (3) getPage()方法设计思路见重难点。

### 2.重难点: getPage()方法

利用 buffer 和键 pid 定位 Page,如果 buffer 中有该 PageId,则返回它对应的 Page;若 buffer 中还未包含这一页,先判断当前 buffer 容纳的页数是否小于最多可容纳页数 numPages;若小于,则通过目录定位该数据库文件,再调用 readPage(pid)方法获取该页,将该 pageId 和 page 添加到 buffer 中,并返回该页;若 buffer 中空间不足,则抛出异常。

3.改动部分: 未改动 API 和测试代码。

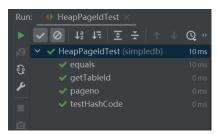
## 六、HeapFile 访问方法—HeapPage 实现

每一个 HeapFile 对象对应一张表,包含一组物理页。

### (一) HeapPageId 类

#### 1.设计思路

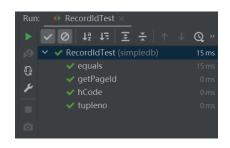
- (1) HeapPageId 是为每个 HeapPage 设立的独特的标识。根据构造方法的参数列表可知,它包括 HeapPage 所属的 HeapFile 所对应的 tableId 和该页在表中的页数 pgNo。应添加属性 tableId 和 pgNo,并在构造方法中初始化。
  - (2) getTableId()和 getPageNumber()方法只需返回相应的属性。
- (3) hashCode()方法中需要为该页设置一个哈希码,将 tableId 和 pgNo 对应的字符串拼接,再返回该字符串对应的 hashCode()。
- (4) 比较给出的对象是否与该 HeapPageId 相等,整体思路与 TupleDesc 类中 equals()方法相同。
- 2.改动部分:未改动 API 和测试代码
- 3.test 测试结果如下:



#### (二) RecordId 类

#### 1.设计思路

- (1) RecordId 是对一张特定表的特定页的特定元组的编号。由构造方法的参数列表可知,它包括元组所在页的 PageId 和该元组在页中的元组数 tupleNo。因此需添加这两个属性,并通过构造方法进行初始化。
  - (2) getTupleNumber()和 getPageId()方法只需返回相应的属性。
  - (3) hashCode()方法和 equals()方法的整体思路与 HeapPageId 类中相同。
- 2.改动部分: 未改动 API 和测试代码
- 3.test 测试结果如下:



## (三) HeapPage 类

每个 HeapPage 实例存 HeapFile 中一页的数据,并实现 Page 接口。页的大小由 BufferPool.DEFAULT\_PAGE\_SIZE 定义。每页里有一些 slots,每个 slot 存一个表中的元组。每页还有一个 header,其中有每一位通过 bitmap 指示每个 tuple,1 代表有效,0 代表无效(被删了或从未初始化)。

#### 1.设计思路

- (1) getNumTuples()方法需要计算出该页中元组的个数。已知页的大小按位表示为 BufferPool.getPageSize()\*8, 每个元组的大小按位表示为 tupleDesc.getSize()\*8,还需为每个元组留出 1 位给 header 作映射。因此该页中元组的个数为 tuples per page = floor((page size \* 8) / (tuple size \* 8 + 1)),代入即可。
- (2) getHeaderSize()方法需要计算出该页中 header 的字节数。计算方法为 header bytes=ceiling(tuples per page / 8),调用函数代入 tuples per page 即可。
  - (3) getId()方法只需返回属性 pid。
- (4) getNumEmptySlots()方法需要计算出该页中空的 slots 的个数。只需对所有的 slots 进行遍历,调用 isSlotUsed(i)函数判断第 i 个是否填有元组,统计所有非空的个数。
  - (5) isSlotUsed()方法和 iterator()方法的设计思路见重难点。

### 2.重难点

(1) 判断第 i 个 slot 是否填有元组 (isSlotUsed()方法)

第 i 个 slot 前 header 中应该已经填满 header 中 i/8 个字节, 令 pre=i/8; 第 i 个 slot 应该对应 header 中第(i/8+1)个字节的 i%8 位, 令 remain=i%8。slot 对应的 位为 header[pre]>>remain, 判断它是否为 1, 若为 1 则填有元组。

(2) 获取所有元组的 iterator()方法

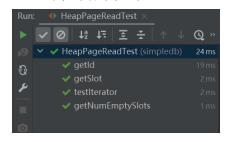
可以创建一个辅助类 HeapPageTupleIterator,实现 Iterator 接口。在其中添加

元素类型为 Tuple 的迭代器 tupleIterator 和动态数组 tupleArrayList。在构造方法中遍历所有 slots,向 tupleArrayList 中添加对应的元组,并将它调用 iterator()方法的返回值赋给 tupleIterator。重写 hasNext()和 next()方法,返回 tupleIterator 的 hasNext()和 next()。重写 remove()方法,按要求抛出异常。

在 HeapPage 类中的 iterator 方法内,创建 HeapPageTupleIterator 类对象并返回即可。

3.改动部分:未改动 API 和测试代码

4.test 测试结果如下:



## 七、HeapFile 访问方法—HeapFile 类实现

#### 1.设计思路

- (1) HeapFile 类实现 DbFile 接口,由存元组的页组成,每个 HeapFile 实例对应一张表。根据 HeapFile 的构造方法的参数列表可知,需要添加属性 File 类对象 file 和 TupleDesc 类对象 tupleDesc,并通过构造函数初始化。两个属性值通过相应的 get 方法返回获取。
- (2) getId()方法需要为每个 HeapFile 实例生成一个独特的 ID 值(也是对应的表的 tableId)。可以用 HeapFile 的绝对路径生成 HashCode 作为 ID。
- (3) numPages()方法需要计算该 HeapFile 中有多少页。文件的大小为 file.length(),每页的固定大小由 BufferPool 中定义。因此 page number=floor(file length / page size)。
  - (4) readPage()方法和 iterator()方法的设计思路见重难点。

## 2.重难点

(1) readPage()方法,读取磁盘上某一特定页。

由 HeapPage 类的构造方法可知,要创建一个 HeapPage 对象,需要相应的 HeapPageId 对象和一个向其中写入该页数据的字节数组;由 HeapPageId 类的构

造方法可知,需要相应的 tableId 和 pgNo 来创建一个 HeapPageId 对象。

通过参数 pid,调用两个 get 方法,可以得到相应的 tableId 和 pgNo。调用 HeapPage 类中的静态方法 createEmptyPageData,可以得到一个空页对应的字节 数组 bytes。通过文件输入流读取该 HeapFile 文件,跳过前 pgNo\*pageSize 个字节,定位到该页对应的第一个字节。从当前位置开始,读取 pageSize 个字节,将 数据存到 bytes 数组中。利用得到的 tableId,pgNo 和 bytes 创建一个 HeapPage 对象,返回该对象。

若读取过程中发现文件不存在,抛出异常。

(2) 获取该 HeapFile 上所有元组的 iterator()方法。

创建辅助类 HeapFileIterator,实现接口 DbFileIterator。迭代器需要通过 BufferPool 获取各页,需要 transactionId,HeapPageId。因此需要属性 HeapFile 对象 heapFile,TransactionId 对象 tid,开始迭代时的页数 openPgNo,以及元素类型为 Tuple 的迭代器 tupleIterator。通过构造方法进行初始化。

需要编写方法获取根据当前 heapFile 和 openPgNo 获取元组的迭代器 tupleIterator, 添加方法 getTupleIterator(int pgNo)。通过 heapFile 的 getId()方法生成 tableId ,与 pgNo 一起构成 HeapPageId 对象 pid。通过 Database.getBufferPool().getPage()方法,经过缓冲池获得 HeapPage 对象 heapPage。heapPage 调用在 HeapPage 类中添加好的 iterator()方法即可返回该页对应的 tupleIterator。

接着需要实现接口 DbFileIterator 定义的几个方法。open()方法需要打开此迭代器,设置开始迭代时的页数 openPgNo 为 0,调用 getTupleIterator()方法,传进openPgNo 即可。

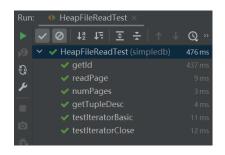
对于 hasNext()方法,首先判断 openPgNo 是否为空,若不为空,循环执行直到所有页都被迭代器访问过。当 tupleIterator.hasNext()返回为真时,表示迭代器里还有元组,返回真;反之,则使 openPgNo 加 1,调用 getTupleIterator()方法向tupleIterator 中添加下一页的元组。对于 next()方法,若 hasNext()为真,则返回tupleIterator 的 next()方法;否则抛出异常。

对于 close()方法,只需将开启页数 openPgNo 和元组迭代器 tupleIterator 置空。rewind()方法要求重置迭代器,只需先调用 close()关闭,再调用 open()打开

迭代器。

完成辅助类后,对于 HeapFile 类中的 iterator()方法,只需创建一个 HeapFileIterator 对象并返回即可。

- 3.改动部分: 未改动 API 和测试代码
- 4.test 测试结果如下:



## 八、操作符 Operators (SeqScan 类)

#### 1.设计思路

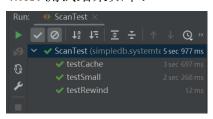
- (1)数据库的操作符负责查询语句的具体执行,基于迭代器实现,每一个operator 都实现了一个 DbFileIterator 接口。SeqScan 操作符顺序扫描特定表的页中的所有元组,需要用到在上一个类 HeapFile 中实现的 iterator()方法。
- (2) 根据 SeqScan 类的操作要求和构造方法的参数列表,可以确定需要添加的属性为 TransactionId 类的对象 tid,表的 tableId,表的别名 tableAlias,要访问的 dbFile 和迭代器 dbFileIterator。通过构造方法初始化。通过 getAlias()方法获取 tableAlias。通过 reset()函数进行重置。
- (3) getTupleDesc()方法需要返回该表对应的元组模式,并且需要按照要求在模式的 fieldName 域前加上前缀 tableAlias。通过 dbFile 的 getTupleDesc()方法即可获取模式,为每个 filedName 前加上 tableAlias 后,创建一个 TupleDesc 对象并返回。
- (4) hasNext(), next(), close(), rewind()方法, 只需通过 dbFileIterator 调用 HeapFile 类中实现的 iterator()方法即可。

## 2.重难点

SeqScan类的重点在于把握它的访问是通过HeapFile类中的迭代方法iterator() 实现的,只需合理调用即可。

3.改动部分: 未改动 API 和测试代码

## 4.test 测试结果如下:



## 九、一次简单的查询

通过创建 test 数据和 test 代码,通过命令行运行测试,得到查询结果。

```
D:\SimpleDB\SimpleDB>ant
Buildfile: D:\SimpleDB\SimpleDB\build.xml

compile:

dist:

BUILD SUCCESSFUL

Total time: 0 seconds

D:\SimpleDB\SimpleDB>java -classpath dist/simpledb.jar simpledb.test

1 1 1

2 2 2 2
```